

할루시네이션을 활용한 AI 소설 생성 서비스

캡스톤디자인II 프로젝트 중간 점검 보고 · Novel Studio

팀명 [기입 필요]
팀원 [기입 필요]
제출일 2026년 9월 14일
보고 범위 2026년 7월 ~ 9월 (캡스톤디자인II 구간)
저장소 https://github.com/gitUserKHS/novel_jepa_kg

0. 프로젝트 목표

LLM의 할루시네이션은 제거 대상이 아니라 창작의 재료다.

검색·요약·질의응답에서 모델이 없는 사실을 지어내는 것은 명백한 결함이다. 그러나 소설에서 지어내기는 결함이 아니라 **일 그 자체**다. 문제는 "어떻게 없앨 것인가"가 아니라 "**이야기를 무너뜨리지 않으면서 어떻게 쓸 것인가**"이다.

이 프로젝트는 할루시네이션을 두 손잡이로 다룬다. **얼마나 지어낼지**를 사용자가 고르고, **지어낸 것이 앞서** **확정된 설정을 배신하지 않는지**를 시스템이 검사한다. 전자가 없으면 밋밋하고, 후자가 없으면 이야기가 무너진다.

1. 지난 학기 및 방학 동안 진행한 내용과 주요 결과물

1.1 구간 구분

캡스톤디자인I(~6월)에서 연구 파이프라인을 완성했다(작업 100건). 합성 서사 데이터 생성 → 임베딩 → JEPA 예측기 학습 → 평가로, *지어낸 전개가 그럴듯한지*를 잠재 공간에서 판정하려는 **가설**이었다. 이번 구간에서 이 가설을 측정했고, 그 결과 소비자 경로에서 철회했다(1.6).

캡스톤디자인II(7월~)는 이것을 **사람이 실제로 쓰는 서비스로 만드는 구간**이다. 7월 19일부터 9월 14일까지 **31회 커밋, 63개 작업**을 수행했다.

1.2 이번 구간에 한 일

#	작업	시기	내용과 결과
①	회원가입·계정	7월 8월	계정 생성·로그인(scrypt 해시), 서버측 세션, 작품의 계정 소유권 격리. 새로고침해도 로그인에 풀리지 않도록 세션 쿠키로 보완
②	프론트엔드	8월	기획 대화 화면, 집필 화면, 원고·템플릿 열람, 작품 설정 조회·수정, 원고 초기화·삭제, 생성 중인 글이 한 글자씩 흘러나오는 실시간 출력
③	돌림노래(반복 루프) 버그 수정	8월	같은 문장·사건이 되풀이되던 문제. 직전 장 전문을 문맥에서 빼고 요약·상태 원장으로 대체, 반복 구간은 장을 다시 쓰지 않고 건너내는 방식으로 전환
④	결말이 안 나오는 문제 수정	7월	목표 분량에 도달해도 갈등이 열린 채 끝나던 문제. 완결 판정을 글자 수가 아니라 결말 장이 실제로 쓰였는 지로 바꾸는 계약 도입
⑤	할루시네이션이 일으키는 버그 대응	8월 9월	아래 1.4에서 상세히 기술. 이 프로젝트의 핵심 주제이자 최대 난제
⑥	모델 자립·교체	8월 9월	외부 API 의존을 끊고 자체 Qwen3.5-4B 서버로 이전(8월) 후, 품질 한계를 확인하고 Gemma4 26B-A4B 로 재교체(9월)
⑦	자동 이어쓰기·원고 수정	8월	사람 개입 없이 최대 20턴 연속 집필, 이미 쓴 장을 고쳐도 이야기 메모리가 어긋나지 않도록 연동
⑧	JEPA 접근 검증 및 철회	8월	캡스톤의 핵심 가설을 측정한 결과 개연성 판정에 유의미하지 않아 소비자 경로에서 제거. 아래 1.6 참조

1.3 할루시네이션 강도를 사용자가 고른다

집필 화면의 **0~1 슬라이더**로 정한다(0 = 정해진 설정에 붙어 쓰기, 1 = 마음껏 지어내기). 처음에는 안정·균형·대담 세 단계였으나, "할루시네이션을 얼마나 쓸 것인가"가 이 프로젝트의 변수라면 그 변수는 연속값이어야 한다고 판단해 9월에 슬라이더로 바꿨다. 값은 프롬프트 문구가 아니라 실제 샘플링 온도로 연결되고 (`_creativity_temperature()`, 0.35 가 기본 온도), 턴마다 저장돼 자동 이어쓰기가 같은 강도를 물려받는다. **지어 내기의 양을 작가가 연속적으로 조절**한다는 것이 이 서비스의 첫 번째 축이다.

1.4 할루시네이션이 일으킨 고장과 대응 (작업 ⑤ 상세)

할루시네이션은 이 프로젝트의 재료인 동시에 버그의 최대 원인이었다. 세 유형으로 나타났다.

고장 유형	증상	대응
형식 이탈	모델이 요구한 형식을 무시해, 내부 관리용 JSON 기록이 소설 본문에 그대로 출력됨	모델이 형식을 지킬 것이라 믿지 않는다. 여러 표기 변형을 모두 인식하고, 형식이 깨져도 본문에 새지 않도록 최종 차단
설정 배신	없던 인물·사건을 지어내며 확정된 설정과 충돌 (아래 사례)	인과 설계 → 연속성 검토 → 고쳐 쓰기 3단 장치 (1.5)
검사기의 오판	검사 장치 자체가 정상을 문제로 오인. 로맨스의 역할 호칭("아가씨")을 지어낸 인물명으로 판정해 매 장을 불필요하게 다시 씀	호칭 판정 규칙을 좁혀, 기존 인물명과 닮은 경우에만 의심하도록 수정

1.5 지어낸 것을 설정에 묶는 개연성 장치 (9월 신규)

자유롭게 지어내게 두면 이야기가 무너진다. 그래서 **지어내기를 금지하는 대신, 지어낸 것이 기존 설정과 충돌하는지만 검사하는** 3단 절차를 넣었다. ① 장을 쓰기 **전에** 목표·장애·전환·결과를 설계하고, ② 쓴 **뒤에** 연속성 편집자 역할의 모델이 확정 사실·직전 장면과의 모순을 1~10점으로 검토하며, ③ 모순이 있거나 7점 미만이면 초안을 넣고 **문제만** 바로잡은 뒤 재검토해 더 나올 때만 채택한다.

이 장치가 하는 일을 보여 주는 실제 사례. 모델이 작품에 없던 개 "콩떡"을 지어냈다 — 분위기를 살리는 좋은 할루시네이션이다. 그런데 본문에서 그 개가 **"하린아, 또 그거 보고 있어?"라고 말했다** — 설정을 배신하는 **나쁜** 할루시네이션이다.

초기 검토는 이를 놓치고 두 장 모두에 10점을 줬다. "동물이 말하면 모순"이라는 일반 지시를 추가해도 여전히 놓쳤다. 검토 절차에 **모든 대사를 화자에** 배정하게 만들자 (`quote·speaker·can_speak`) 즉시 잡아냈다.

중요한 것은 **고쳐 쓴 결과**다. 게이트는 개를 지우지 않았다. 개는 남고, 개의 대사만 서술로 바뀌었다. **창작은 살리고 모순만 걷어낸다** — 이것이 "할루시네이션 활용"의 구체적인 모습이다.

부수적 교훈: 모델은 자기 글의 오류를 "찾아라"라고 하면 못 찾고, **"열거하라"**고 하면 찾는다.

1.6 JEPA 접근의 검증과 철회 (작업 ⑧ 상세)

캡스톤I의 핵심 가설은 **"다음 장면의 의미 벡터를 예측해, 실제로 쓰인 장과의 코사인 유사도로 개연성을 판정한다"**였다. 예측기를 학습해 품질 게이트까지 통과시키고, 임계값을 실제 생성물로 보정한 뒤 측정했다. 결과는 **가설을 지지하지 않았다**.

표본	n	최저	평균	최고
정상적으로 이어진 장	6	0.651	0.708	0.766
의도적으로 인과를 끊은 장	6	0.502	0.596	0.637

측정에서 드러난 세 가지 한계다.

- **판정 여유가 없다.** 정상 of 최저(0.651)와 파손 of 최고(0.637) 사이가 **0.014**뿐이다. 표본이 조금만 달라져도 두 분포가 겹친다 (실제로 이전 모델에서는 겹쳤다).
- **장르마다 눈금이 달라진다.** 같은 임계값인데 판타지 미스터리 of 바닥은 0.732, 법정 미스터리 of 0.651이었다. 한 장르로 맞춘 값이 다른 장르에서는 멀쩡한 장을 다시 쓰게 만든다.
- **유사도는 인과가 아니다.** 일부러 어긋나게 짝지은 쌍조차 0.497 아래로 내려가지 않았다. 임베딩이 값을 압축해, 이 지표는 **완전한 판소리**를 걸러낼 뿐 인과를 증명하지 못한다.

왜 구조적으로 어려운가. 개가 **"하린아"**라고 말하는 문장과 사람이 같은 말을 하는 문장은 의미 벡터상 거의 구분되지 않는다. 문장 임베딩은 무슨 일이 일어났는가는 어느 정도 담지만 그 일이 일어날 수 있는가는 담지 않는다. 개연성 판정에 필요한 것은 후자였다.

그래서 2026년 8월 23일, JEPA·임베딩·검색을 소비자 경로에서 제거했다. 당시 기록: **"의존성 비용은 치르면서 품질은 얻지 못한다."** 대신 도입한 LLM 연속성 검토는 같은 개 사례를 실제로 잡아냈다(1.5).

다만 **버리지는 않았다**. 학습 파이프라인과 평가 지표는 연구용 관리자 도구에 보존해, 캡스톤I의 산출물과 비교 근거가 남아 있다. 이 검증은 실패가 아니라 **"측정해서 아니라고 확인한 결과"**이며, 지금의 개연성 장치를 선택한 직접적인 이유다.

1.7 결과물 규모

항목	규모
본체 코드	18,462줄
테스트	30개 파일 · 5,367줄 · 269개 테스트 전부 통과
CI	GitHub Actions — 푸시마다 단위 테스트 + 파이프라인 스모크 테스트
실제 생성	작품 4편, 생성 작업 7건 중 6건 성공, 1편 완결(11,714자·5장)
성능 (RTX 4060 8GB)	17GB 모델을 VRAM 4.6 GiB + RAM 분할 적재, 디코드 27~30 tok/s, KV 캐시로 반복 호출 16.4초 → 0.4초

2. 현재 프로젝트 완성도

90%

2.1 구간 내 진척 추이

시점	누적	도달 상태
7월 말	40%	서비스 뼈대 완성 — 계정·큐·워커·작품 격리 저장, 결말 계약 도입
8월 말	75%	사용 가능한 제품 — 프론트엔드, 실시간 출력, 반복 루프 수정, 자동 이어쓰기, 원고 수정, 자체 모델 서버
9월 현재	90%	주제 구현 완료 — 26B 모델 교체, 개연성 장치 도입, 할루시네이션 3대 고장 유형 대응
9월 말 (목표)	97%	검증 완료 — 다이얼 효과 측정, 3만 자 완주, 사람 평가 확보

2.2 영역별 산정

영역	가중치	완성도	근거
핵심 개념 구현 (할루시네이션 활용)	35%	95%	강도 조절(0~1 슬라이더)과 구속(개연성 장치) 양축이 모두 동작하며 실제 사례로 효과 확인
서비스 기능	25%	95%	회원가입~완결 전 과정 동작. 이번 구간 63개 작업 완료
안정성·테스트·문서	20%	92%	269개 테스트 통과, CI 녹색, 신규 참여자 설치 경로 실제 클론으로 검증
실사용 검증	12%	80%	1편 완결·작업 6/7 성공. 기본 목표인 3만 자 구간은 미완주
외부 평가	8%	65%	자체 지표는 있으나 사람 평가 미실시
가중 합계		90%	

산정 근거. 목표로 삼은 "할루시네이션을 활용하는 소설 생성 서비스"는 개념·구현·서비스가 모두 갖춰져 실제로 소설을 완결까지 생산한다. 남은 10%는 새로 만들 기능이 아니라, 만든 것이 더 긴 분량과 사람 독자 앞에서 통하는지 확인하는 일이다.

3. 현재 미비하거나 추가 보완이 필요한 부분

① 할루시네이션의 "유용성"을 아직 재지 못한다 (가장 중요)

현재 장치는 *해로운* 할루시네이션(설정 모순)만 판정한다. 그러나 목표는 지어내기를 *활용*하는 것이므로, "대담"으로 올렸을 때 실제로 더 풍부해지는지를 재는 지표가 필요하다. 연구 구간에서 만든 `useful_hallucination_score` 창의적 확장률 지표가 남아 있으나 현재 서비스 경로에 연결돼 있지 않다. **다이얼**을 돌린 효과를 아직 증명하지 못한 상태다.

② 품질 평가가 자기 채점에 머물

개연성 점수는 같은 모델이 자기 글을 채점한 값이다. 개가 말하는 장면엔 10점을 준 사례가 한계를 보여 준다. 사람이 읽고 평가한 결과나 독립적인 비교 기준이 없다.

③ 목표 분량 완주 미검증

완결된 작품은 1만 자 목표 1편이다. 기본값은 3만 자, 최대 5만 자인데 이 구간을 끝까지 써 본 기록이 없다. 길이가 늘수록 앞 내용을 요약으로 압축해 넣는 구조라, **후반부에서 초반 설정이 흐려지는지**가 확인되지 않았다.

④ 생성 속도와 운영 제약

3,755자에 276초였으므로 3만 자는 약 35~40분이 필요하다. 또한 워커는 한 번에 한 작업만 처리하며 다중 사용자 동시 요청은 검증하지 않았다. 개연성 임계값도 미스터리.판타지 위주로 조정돼 있어 장르별 오탐 가능성이 남아 있다.

⑤ 철회한 접근의 코드가 남아 있다

검증 후 철회한 JEPA 파이프라인(1.6)과 8월의 Qwen 모델 서버가 연구용 관리자 도구에 보존돼 있다. 비교 근거로 남긴 것이라 삭제할 계획은 없으나, 현재 서비스와 설치 의존성·CI 시간을 공유하고 있어 **연구용과 서비스용**을 분리하는 정리가 필요하다.

4. 향후 프로젝트 진행 및 완성 계획

9월 말까지 "거의 완료" 상태 도달을 목표로 한다. 남은 작업은 새 기능 개발이 아니라 검증이므로, 2주 안에 집중 수행이 가능하다.

기간	목표	내용
9/15~9/21	다이얼 효과 측정	같은 기획으로 안정·균형·대담 3회 생성 후 창의적 확장률·유용한 할루시네이션 점수·모순 발생률을 비교. <i>대담이 실제로 더 나은가</i> 에 대한 데이터 확보 (프로젝트 목표의 직접 증명)
9/15~9/21	3만 자 완주 검증	기본 목표 분량을 끝까지 생성하고 장별 개연성 점수·설정 유지·소요 시간 기록. 후반부 붕괴 지점이 있으면 특정해 보완
9/22~9/28	사람 평가 및 보완	생성물을 팀원·외부 독자가 블라인드 평가하고 모델 자기 채점과의 상관을 측정. 위 두 검증에서 나온 문제를 우선순위대로 수정
9/29~9/30	최종 점검 → 97%	전체 회귀 테스트, 문서 갱신, 시연 시나리오 확정
10월 이후	확장 및 대외 활동	속도 개선(설계·검토 호출 통합), 다중 사용자 대응, 레거시 코드 분리, 캡스톤디자인 경진대회 출품 준비

완성의 기준

이 프로젝트가 "완성"되었다고 말하려면 다음을 보여야 한다고 본다.

- **할루시네이션 강도를 올렸을 때 더 풍부해지면서도 모순은 늘지 않는다는 것을 수치로 보일 것** — 프로젝트 목표의 직접적 증명
- 3만 자 장편을 완주하고 후반부에서도 초반 설정이 유지될 것
- 사람 독자의 평가가 확보되고 모델 자기 채점과의 차이가 설명될 것